



**UNIVERSIDAD TECNOLÓGICA DE LA
HUASTECA HIDALGUENSE**

Organismo Descentralizado de la Administración Pública Estatal

INGENIERÍA EN DESARROLLO Y GESTIÓN DE SOFTWARE



MATERIA: EXTRACCIÓN DE CONOCIMIENTO EN BASES DE DATOS

PROYECTO MES 3

ALUMNO:

20221019-----DE LA CRUZ HERNÁNDEZ OSCAR DAVID

20230068-----OLVERA MORALES LIZBET

DOCENTE: DR. EFRÉN JUAREZ CASTILLO

GRADO:9NO CUATRIMESTRE GRUPO: C

URL Pública: <https://pry-bina-front.vercel.app/>

Índice

1. Introducción	4
1.1 Contexto de la empresa	4
1.2 Descripción general del sistema web	4
1.3 Objetivo general del proyecto	5
1.4 Objetivos de las soluciones analíticas	5
2. Definición de las dos soluciones analíticas	7
2.1 Solución 1: Clasificación de riesgo de cancelación	7
2.2 Solución 2: Sistema de recomendación de productos	8
2.3 Validación de coherencia y viabilidad	10
2.4 Justificación del valor agregado	14
3. Base de datos de origen y volumen de información.....	17
3.1 Base de datos del proyecto	17
3.2 Colecciones utilizadas	17
3.3 Volumen de registros	18
3.4 Datos reales y sintéticos	19
3.5 Respaldo y privacidad	21
4. Extracción, transformación y construcción de datasets	23
4.1 Dataset de clasificación	23
4.2 Dataset de recomendación.....	25
4.3 Unidad de análisis de cada dataset	26
4.4 Trazabilidad de columnas.....	29
4.5 Verificación del proceso.....	32
5. Desarrollo CRISP-DM: Solución 1, Clasificación.....	34
5.1 Comprensión del negocio.....	34
5.2 Comprensión de los datos	35
5.3 Preparación de los datos	35
5.4 Modelado.....	36
5.5 Evaluación.....	36
5.6 Despliegue e integración	36
6. Desarrollo CRISP-DM: Solución 2, Recomendación	38
6.1 Comprensión del negocio.....	38

6.2 Comprensión de los datos	38
6.3 Preparación de los datos	39
6.4 Modelado.....	39
6.5 Evaluación.....	39
6.6 Despliegue e integración	39
7. Requisitos específicos según el tipo de solución	40
7.1 Solución 1: Clasificación del Riesgo de Cancelación	40
7.2 Solución 2: Sistema de Recomendación (Filtrado Colaborativo Ítem-Ítem)	41
8. Integración en el sistema web	43
8.1 Arquitectura general	43
8.2 Integración del modelo de clasificación.....	43
8.3 Integración del recomendador	44
8.4 Endpoints y servicios utilizados.....	45
8.5 Actualización de modelos o cálculos	46
9. Evidencias de funcionamiento	47
9.1 Evidencias de clasificación	47
9.2 Evidencias de recomendación	49
10. Resultados, limitaciones y mejoras	54
10.1 Resultados obtenidos.....	54
10.2 Limitaciones de los datos	55
10.3 Riesgos de errores del modelo	56
10.4 Mejoras futuras.....	57
11. Conclusiones	58
12. Bibliografía.....	60

1. Introducción

1.1 Contexto de la empresa

Distribuidora Panamericana es una empresa perteneciente al sector *retail* orientada a la comercialización de productos de belleza, cosmética y herramientas profesionales de barbería, operando bajo esquemas de venta al mayoreo y menudeo.

La estructura organizacional de la empresa está compuesta por 4 colaboradores fijos: 1 Dueño/Administrador, 2 Cajeros y 1 Almacenista. Históricamente, la empresa operaba mediante registros manuales en bitácoras y libretas en papel, lo cual ocasionaba falta de estandarización en los códigos de los artículos, descuadres en el corte de caja, pérdidas económicas por ventas perdidas y desabasto de mercancía crítica.

Para resolver esta problemática operativa, la empresa inició un proceso de transformación digital integral orientado a centralizar su catálogo y migrar hacia un canal de ventas digital moderno e inteligente.

1.2 Descripción general del sistema web

Para atender las necesidades operativas y comerciales de Distribuidora Panamericana, se desarrolló e implementó un **Sistema Web de Gestión Integral e-Commerce** construido sobre una arquitectura cliente-servidor desacoplada de tres capas:

- **Frontend:** Desarrollado en **Angular 17+** (TypeScript, HTML5, Vanilla CSS, Angular Material), ofreciendo una interfaz de usuario fluida (*Single Page Application*) para clientes y administradores.

- **Backend:** Construido en **Node.js** con **Express.js**, actuando como una API RESTful encargada del procesamiento transaccional, autenticación JWT y consumo de algoritmos analíticos.
- **Base de Datos:** Implementada en **MongoDB** mediante el ORM **Mongoose**, garantizando una gestión no relacional flexible para usuarios, productos, pedidos y catálogos.

El sistema web integra dos módulos clave:

1. **Módulo de Tienda Abierta (E-commerce Cliente):** Catálogo digital interactivo, buscador con filtros por marca y familia, carrito de compras dinámico y pasarela de pago (PayPal / Transferencia / Efectivo).
2. **Módulo de Administración (Admin Dashboard):** Gestión centralizada de pedidos, control de inventarios, usuarios y panel de métricas analíticas predictivas en tiempo real.

1.3 Objetivo general del proyecto

Desarrollar e implementar un Sistema Web de Gestión e-Commerce con Analítica de Datos Integrada para Distribuidora Panamericana, logrando la automatización completa de los procesos de inventario y ventas, la reducción de pérdidas operativas y el incremento de la rentabilidad del negocio a través de la toma de decisiones informada.

1.4 Objetivos de las soluciones analíticas

Como valor agregado al sistema web, se incorporaron dos soluciones de Inteligencia de Negocios y Machine Learning integradas en el backend de Node.js:

Solución 1: Clasificación Predictiva del Riesgo de Cancelación (Random Forest)

- **Objetivo Analítico:** Construir y desplegar un modelo supervisado de clasificación binaria que evalúe y prediga la probabilidad de cancelación de un pedido (\$y=1\$) en el momento exacto en que es registrado en la plataforma.
- **Meta de Negocio:** Permitir al equipo administrativo anticipar y prevenir hasta un 74.7% de las cancelaciones no gestionadas, reduciendo costos de logística inversa y evitando la inmovilización de stock apartado en almacén.

Solución 2: Sistema de Recomendación de Productos (Filtrado Colaborativo Ítem-Ítem)

- **Objetivo Analítico:** Implementar un algoritmo no supervisado basado en **Similitud Coseno por Coocurrencia** sobre la matriz de compras entregadas pasadas.
- **Meta de Negocio:** Recomendar automáticamente los 6 productos con mayor afinidad respecto a los artículos presentes en la cesta del usuario, estimulando la venta cruzada (*Cross-Selling*) y aumentando el número promedio de piezas por pedido.

2. Definición de las dos soluciones analíticas

2.1 Solución 1: Clasificación de riesgo de cancelación

Elemento	Información
Nombre de la solución	Predicción de riesgo de cancelación de pedidos
Necesidad de negocio	El administrador necesita identificar qué pedidos pendientes tienen mayor probabilidad de cancelarse para priorizar su revisión, confirmación o seguimiento antes de que el pedido se pierda.
Pregunta analítica	¿Qué probabilidad tiene un pedido pendiente de terminar cancelado, usando la información disponible al momento de registrar el pedido?
Tipo de solución	Clasificación supervisada
Unidad de análisis	Un pedido completo. Cada renglón del dataset representa un pedido con sus datos de usuario, productos, pago, envío, historial y resultado final.
Resultado esperado	Probabilidad y nivel de riesgo de cancelación: bajo, medio o alto. La clase objetivo es clase_y, donde 1 = Cancelado y 0 = Entregado.
Datos de origen	Colecciones pedidos, usuarios y datos contenidos en pedidos.productos[]. Dataset generado: dataset_clasificacion.csv.

Usuario dentro del sistema	Administrador del sistema.
Decisión apoyada	Priorizar la atención de pedidos pendientes con mayor riesgo, revisar datos del cliente, confirmar pago o dar seguimiento antes de actualizar el estado del pedido.
Pantalla de integración	Módulo administrativo de Gestión de Pedidos, sección de riesgo de cancelación.

2.2 Solución 2: Sistema de recomendación de productos

Elemento	Información
Nombre de la solución	Recomendación de productos relacionados
Necesidad de negocio	El cliente puede no conocer productos complementarios o relacionados. El sistema busca apoyar la venta cruzada recomendando artículos que suelen comprarse junto con los productos consultados o agregados al carrito.
Pregunta analítica	¿Qué productos pueden recomendarse porque históricamente han aparecido junto con los productos seleccionados por el cliente?
Tipo de solución	Sistema de recomendación mediante filtrado colaborativo item-item

Unidad de análisis	Presencia de un producto dentro de un pedido entregado. Cada renglón del dataset representa que un producto apareció en una transacción de compra finalizada.
Resultado esperado	Lista ordenada de productos recomendados, calculada por similitud entre productos.
Datos de origen	Colecciones pedidos y productos. Se usan pedidos con estado Entregado, el arreglo pedidos.productos[] y el catálogo de productos activos con stock. Datasets generados: dataset_recomendacion_interacciones.csv y dataset_productos.csv.
Usuario dentro del sistema	Cliente que navega el catálogo o revisa su carrito de compras.
Decisión apoyada	Sugerir productos relacionados para que el cliente pueda agregarlos al carrito, aumentando la personalización y la posibilidad de venta cruzada.
Pantalla de integración	Vista de detalle del producto y carrito de compras, en la sección de productos recomendados.

2.3 Validación de coherencia y viabilidad

Solución 1: Clasificación de riesgo de cancelación de pedidos

Pregunta de validación	Evidencia requerida
¿Qué representa exactamente un renglón?	Cada renglón representa un pedido completo registrado en el sistema. Incluye información del cliente, productos, método de pago, envío, fecha, historial previo y estado final del pedido.
¿Qué se desea predecir, estimar, agrupar o recomendar?	Se desea predecir si un pedido pendiente tiene riesgo de terminar cancelado. La variable objetivo utilizada durante el entrenamiento es clase_y, donde 1 = Cancelado y 0 = Entregado.
¿En qué momento se generará el resultado?	El resultado se genera cuando el administrador consulta el módulo de Gestión de Pedidos. El modelo analiza pedidos con estado Pendiente, es decir, pedidos cuyo resultado final aún no se conoce.
¿Qué información estará disponible en ese momento?	Al momento de registrar el pedido ya están disponibles el usuario, edad calculada desde fecha de nacimiento, productos seleccionados, cantidades, precios, total, costo de envío, método de pago, fecha de compra, dirección de envío y el historial previo del cliente.
¿Por qué cada columna puede	Las variables del pedido pueden reflejar patrones relacionados con cancelaciones. Por ejemplo, el método de pago, el costo de envío, el total, la cantidad de productos, la hora de compra y el historial de

aportar información relevante?	cancelaciones previas pueden influir en la probabilidad de que un pedido no se complete.
¿De dónde proviene cada valor?	Los datos provienen principalmente de las colecciones pedidos y usuarios. De pedidos se toman productos, cantidades, precios, total, costoEnvio, metodoPago, estado y fecha. De usuarios se toma fechaNacimiento para calcular edad. El porcentaje de cancelaciones previas se calcula con pedidos anteriores del mismo usuario.
¿Es realmente viable obtener el resultado con esos datos?	Sí es viable porque existen pedidos históricos con estados finales conocidos: Entregado y Cancelado. Estos registros permiten entrenar un modelo supervisado y aplicar la predicción a pedidos pendientes. Además, las columnas usadas están disponibles antes de conocer el resultado final del pedido, por lo que no se fuerza información futura.
¿Cómo se utilizará el resultado en el sistema?	El resultado se muestra en el módulo administrativo de Gestión de Pedidos. El administrador visualiza un porcentaje y un nivel de riesgo: bajo, medio o alto.
¿Qué valor agregado produce?	Permite priorizar el seguimiento de pedidos pendientes, identificar posibles cancelaciones antes de que ocurran y apoyar la toma de decisiones del administrador sin cancelar automáticamente ningún pedido.

Esta solución es coherente porque utiliza como unidad de análisis un pedido completo y predice un resultado relacionado directamente con ese pedido. Las variables utilizadas están disponibles

antes de conocer si el pedido será entregado o cancelado, por lo que se evita fuga de información. Los identificadores como pedido_id, usuario_id y nombre_usuario se conservan únicamente para trazabilidad e interpretación en el sistema, pero no se consideran variables predictoras principales.

Solución 2: Sistema de recomendación de productos relacionados

Pregunta de validación	Evidencia requerida
¿Qué representa exactamente un renglón?	Cada renglón representa la presencia de un producto dentro de un pedido entregado. Es decir, indica que determinado producto formó parte de una transacción finalizada.
¿Qué se desea predecir, estimar, agrupar o recomendar?	Se desea recomendar productos relacionados con los productos que el cliente está consultando o tiene en el carrito. El resultado esperado es una lista ordenada de productos recomendados.
¿En qué momento se generará el resultado?	El resultado se genera cuando el cliente visualiza el detalle de un producto o cuando consulta su carrito de compras.
¿Qué información estará disponible en ese momento?	Estarán disponibles los identificadores de los productos que el cliente está viendo o tiene agregados al carrito. También estará disponible el historial de pedidos entregados y el catálogo de productos activos con stock.

¿Por qué cada columna puede aportar información relevante?	El identificador del pedido permite construir transacciones. El identificador del producto permite detectar qué productos aparecen juntos. La presencia permite construir la relación producto-transacción. El catálogo permite mostrar nombre, precio, marca, familia, stock y estado activo de los productos recomendados.
¿De dónde proviene cada valor?	Los datos provienen de las colecciones pedidos y productos. De pedidos se toma _id, estado y productos[].producto. De productos se toma _id, nombre, precioNormal, stock, marca, familia y activo.
¿Es realmente viable obtener el resultado con esos datos?	Sí es viable porque los pedidos pueden contener varios productos, lo que permite construir canastas de compra. A partir de esas canastas se pueden calcular coocurrencias y similitudes entre productos. Si cada pedido tuviera un solo producto, esta técnica no sería adecuada, pero en este sistema los pedidos pueden incluir múltiples artículos.
¿Cómo se utilizará el resultado en el sistema?	El resultado se muestra en la vista de detalle del producto y en el carrito de compras, dentro de una sección de productos recomendados.
¿Qué valor agregado produce?	Ayuda al cliente a descubrir productos relacionados, mejora la experiencia de compra y puede aumentar la venta cruzada al sugerir artículos que históricamente se han comprado juntos.

Esta solución es coherente porque la unidad de análisis corresponde a una interacción producto-transacción. El sistema no intenta predecir una clase, sino ordenar productos según su similitud

con los artículos seleccionados. La información utilizada proviene de compras entregadas, por lo que las recomendaciones se basan en transacciones reales o sintéticas válidas dentro de la estructura de la base de datos.

2.4 Justificación del valor agregado

Solución 1: Clasificación de riesgo de cancelación de pedidos

La incorporación del modelo de clasificación permite que el módulo administrativo de pedidos no solo muestre la información registrada, sino que también ayude a anticipar qué pedidos pendientes tienen mayor probabilidad de cancelarse. Sin esta función, el administrador tendría que revisar los pedidos de forma manual y sin una prioridad clara, basándose únicamente en la fecha, el total o su criterio personal.

Esta solución atiende el problema de seguimiento de pedidos pendientes. El resultado será utilizado por el administrador del sistema, quien podrá observar un porcentaje y un nivel de riesgo de cancelación para cada pedido pendiente. A partir de este resultado, el administrador puede decidir qué pedidos revisar primero, cuáles confirmar con el cliente, cuáles requieren validar datos de envío o método de pago, y cuáles pueden continuar con el flujo normal de atención.

El beneficio esperado es reducir pérdidas por cancelaciones, mejorar el seguimiento de pedidos y organizar mejor el tiempo del personal administrativo. También permite que los pedidos con mayor riesgo no queden ocultos entre otros pedidos pendientes, ya que el sistema los clasifica de forma visible dentro del módulo de Gestión de Pedidos.

El beneficio podría comprobarse posteriormente comparando el porcentaje de pedidos cancelados antes y después de usar la herramienta, midiendo cuántos pedidos de alto riesgo fueron atendidos a tiempo y revisando si disminuye el tiempo promedio de respuesta a pedidos pendientes.

También podrían analizarse los casos en los que el sistema asignó riesgo alto y verificar cuántos terminaron efectivamente cancelados.

Un riesgo de esta solución es que el modelo clasifique como riesgoso un pedido que realmente sí se habría completado. En ese caso, el costo sería dedicar tiempo administrativo adicional a un pedido que no lo necesitaba. Otro riesgo es que un pedido con riesgo real sea clasificado como bajo, lo que podría causar que no se le dé seguimiento oportuno. Por esta razón, la predicción debe utilizarse como apoyo para priorizar la revisión, no como una decisión automática para cancelar o rechazar pedidos.

Solución 2: Sistema de recomendación de productos relacionados

La incorporación del sistema de recomendación permite que el catálogo y el carrito de compras no solo muestren productos disponibles, sino que también sugieran artículos relacionados con lo que el cliente está consultando o agregando a su compra. Sin esta función, el cliente tendría que buscar manualmente productos complementarios, y el sistema perdería la oportunidad de guiarlo hacia artículos que históricamente se han comprado juntos.

Esta solución atiende el problema de personalización y venta cruzada dentro del proceso de compra. El resultado será utilizado por el cliente final mientras navega en la vista de detalle de producto o dentro del carrito. A partir de las recomendaciones, el cliente puede descubrir productos complementarios, comparar opciones y agregar nuevos artículos a su carrito sin tener que buscarlos desde cero.

El beneficio esperado es aumentar la venta cruzada, mejorar la experiencia de navegación y facilitar que el cliente encuentre productos relacionados con su interés actual. Por ejemplo, si un cliente consulta un gel para afeitar, el sistema puede recomendar productos que suelen aparecer en los mismos pedidos, como aceite para barba, navajas o accesorios relacionados.

El beneficio podría comprobarse posteriormente midiendo cuántas veces los clientes hacen clic en productos recomendados, cuántos productos recomendados se agregan al carrito y cuántas ventas incluyen artículos sugeridos por el sistema. También se puede comparar el valor promedio del carrito antes y después de incorporar las recomendaciones.

Un riesgo de esta solución es recomendar productos poco relevantes, agotados o que no correspondan al interés del cliente. Esto podría reducir la confianza del usuario en las sugerencias o distraerlo durante la compra. Otro costo posible es que, si el historial de pedidos es limitado o poco variado, el sistema tienda a recomendar productos populares en lugar de productos verdaderamente complementarios. Por esta razón, el sistema filtra productos activos y con stock, y utiliza productos de respaldo por marca o familia cuando no existe suficiente historial de coocurrencia.

3. Base de datos de origen y volumen de información

3.1 Base de datos del proyecto

La información utilizada para el desarrollo y validación de las dos soluciones analíticas Propuesta 1: Clasificación del riesgo de cancelación con Random Forest y Propuesta 2: Sistema de recomendación colaborativo ítem-ítem proviene de forma directa y exclusiva de la base de datos no relacional MongoDB del sistema e-commerce desarrollado para Distribuidora Panamericana.

De acuerdo con los lineamientos del proyecto integrador, no se utilizaron datasets externos ni plataformas públicas como Kaggle. Todos los datos se estructuraron respetando los esquemas, tipos de datos, restricciones de validación y relaciones de negocio del sistema transaccional del e-commerce.

3.2 Colecciones utilizadas

Las soluciones analíticas se alimentan de tres colecciones principales del sistema en MongoDB:

1. **usuarios:**

- **Propósito:** Almacena el perfil demográfico y de autenticación de los clientes.
- **Campos clave utilizados:** _id, nombre, ap, am, fechaNacimiento (para calcular la edad al momento de la compra), createdAt (para determinar la antigüedad de la cuenta en días) y rol (usuario).

2. **productos:**

- **Propósito:** Almacena el catálogo de artículos de belleza, cosmética y barbería.
- **Campos clave utilizados:** _id, nombre, precioNormal, stock, marca, familia y activo.

3. **pedidos:**

- **Propósito:** Registra las transacciones completas generadas en el e-commerce.
- **Campos clave utilizados:** _id, usuario (FK), productos (arreglo embebido con producto, cantidad, precio y snapshot del nombre), total (subtotal de venta), costoEnvio (monto del flete), metodoPago (PayPal, Transferencia, Efectivo), direccionEnvio.estado (ubicación geográfica de entrega), createdAt (fecha/hora exacta de compra) y estado (Entregado, Cancelado, Pendiente).

3.3 Volumen de registros

El volumen de información almacenado y procesado cumple y supera el mínimo requerido de 2,000 registros útiles para la operación del negocio:

- **Volumen en Base de Datos (MongoDB):**
 - **Colección pedidos:** 8,000 registros transaccionales totales generados y almacenados en la base de datos.

- **Colección usuarios:** 450 usuarios únicos (proporcionando una diversidad demográfica de 15 a 30 compras por usuario).
- **Colección productos:** 300 productos activos en catálogo.
- **Volumen en Datasets de Entrada para los Modelos:**
 - **Propuesta 1 (Clasificación de Cancelación):** 3,000 observaciones útiles completas procesadas con 19 características (13 variables base y 6 derivadas por ingeniería de características).
 - **Propuesta 2 (Recomendación Ítem-Ítem):** 2,696 canastas analizables de pedidos en estado Entregado, generando 6,382 pares de coocurrencia para el cálculo de Similitud Coseno.

3.4 Datos reales y sintéticos

Dado que la empresa no disponía de un historial digitalizado de más de 2,000 ventas previas en formato electrónico, el 100% de las transacciones históricas se generaron de forma sintética con alta fidelidad operativamente razonable, respetando exactamente la estructura del modelo Mongoose.

Script Utilizado y Reproducibilidad

Para garantizar que la generación sea **100% reproducible**, se construyó el script en Node.js **generar_dataset_optimo.js**, el cual utiliza el generador de números pseudoaleatorios de algoritmo **Mulberry32** inicializado con una semilla fija:

SEMILLA = 20260801

Esto garantiza que cualquier miembro del equipo o docente que ejecute `node generar_dataset_optimo.js` obtendrá una buena distribución de los datos

Reglas de Negocio Incorporadas en la Generación

El script no genera patrones triviales ni aleatoriedad pura, sino que simula comportamientos de consumo y riesgo reales:

1. **Riesgo por Método de Pago:** Compras en Efectivo presentan un riesgo de cancelación alto (~46.9%), Transferencia un riesgo medio (~30.7%) y PayPal un riesgo bajo (~18.3%).
2. **Impulsividad Temporal:** Compras realizadas en horario nocturno/madrugada (0:00 a 5:00 AM) o durante fines de semana presentan un incremento en la probabilidad de arrepentimiento y cancelación.
3. **Comportamiento Recurrente y Antigüedad:** Cuentas con menos de 30 días de creadas o usuarios con compras múltiples en menos de 24 horas ($\text{dias_desde_ultimo_pedido} \leq 1$) tienen mayor propensión a la cancelación.

4. **Impacto Económico del Envío:** Costos de flete elevados ($> \$100$ MXN) o montos de pedido altos ($> \$2,000$ MXN) incrementan la sensibilidad al costo y la cancelación. Se aplica la regla de Envío Gratis si total $\geq \$2,500$.

3.5 Respaldo y privacidad

Respaldo e Integridad

Para garantizar la entrega y revisión offline sin requerir conexión activa a la instancia de MongoDB, el sistema exporta automáticamente tres archivos en formato CSV dentro de la carpeta outputs/:

- dataset_clasificacion.csv
- dataset_recomendacion_interacciones.csv
- dataset_productos.csv

Adicionalmente, se incluye el script reproducible .js que permite reconstruir la base de datos completa desde cero en cualquier entorno MongoDB.

Privacidad y Anonimización de Datos

El dataset cumple estrictamente con los estándares de privacidad y protección de datos personales:

- **Nombres e Emails:** Todos los usuarios cuentan con correos sintéticos (cliente_sintetico_X@panamericana.com) y combinaciones de nombres aleatorios.
- **Contraseñas:** Todas las contraseñas están encriptadas mediante la librería **bcrypt** (bcryptjs) con factor de costo 10.
- **Información Sensible:** No se almacenan números de tarjetas de crédito/débito reales, tokens bancarios ni direcciones personales reales. Todos los números telefónicos son números de prueba (5551234567).

4. Extracción, transformación y construcción de datasets

4.1 Dataset de clasificación

Proceso de Extracción y Transformación

El dataset de clasificación (dataset_clasificacion.csv) se construye a partir del volcado transaccional de MongoDB mediante el script automático generar_dataset_optimo.js. El proceso de extracción y preparación sigue un flujo reproducible de 9 pasos:

Consulta a la Colección de Origen: Se ejecuta una consulta a la colección pedidos filtrando por la firma sintética activa:

```
const todosPedidos = await Pedido.find({
  'direccionEnvio.calle': 'SINTETICO_ML_V3'
}).populate('usuario', 'nombre ap am fechaNacimiento createdAt')
  .sort('createdAt 1')
  .lean();
```

Unión de Colecciones (Joins/Populate): Se realiza una relación (FK)

de pedidos.usuario con usuarios._id para extraer la fecha de nacimiento (fechaNacimiento) y la fecha de registro del usuario (createdAt).

Filtro y Orden Cronológico: Los registros se ordenan de forma estrictamente ascendente por fecha de creación (createdAt 1). Esto evita el **sesgo de fuga de datos** (*data leakage*), garantizando que las métricas acumuladas de un cliente solo consideren información de compras pasadas.

Cálculos y Agrupaciones Acumuladas: Conforme se itera sobre los pedidos cronológicos, se mantiene un mapa en memoria historialUsuarios que calcula dinámicamente:

- porcentaje_cancelados_previos: Cancelaciones anteriores del cliente, Total compras anteriores.
- dias_desde_ultimo_pedido: Días transcurridos entre la orden actual y la orden previa del mismo usuario.
- antigüedad_cuenta_dias: Días transcurridos entre fecha_pedido y usuario.createdAt.

Tratamiento de Valores Nulos e Inconsistencias:

- Si la edad o fecha de nacimiento no existe, se asigna la mediana demográfica (28 años).
- Para la primera compra de un cliente (historial.total == 0), porcentaje_cancelados_previos se inicializa en 0.0% y dias_desde_ultimo_pedido se asigna a 999 (indicador neutral de cliente nuevo).

Construcción de Variables Derivadas en Python (Feature Engineering): Al

cargar dataset_clasificacion.csv en la libreta de Jupyter, se generan 5 variables derivadas:

- $\text{precio_promedio_unidad} = \text{total} / \text{total_unidades}$
- $\text{unidades_por_producto} = \text{total_unidades} / \text{num_productos}$
- $\text{prop_costo_envio} = \text{costo_envio} / \text{total}$
- $\text{envio_gratis} = 1.0 \text{ si } \text{costo_envio} == 0 \text{ sino } 0.0$

- $\text{total_real} = \text{total} + \text{costo_envio}$

Codificación de Variables Categóricas (Encoding): Las variables categóricas

(metodo_pago y estado_envio) se convierten automáticamente a representación vectorial numérica (*One-Hot Encoding*) mediante DictVectorizer(sparse=True).

Exclusión de Identificadores: Los identificadores primarios

(pedido_id, usuario_id, nombre_usuario, fecha y resumen_productos) se utilizan únicamente como metadatos de rastreo y se excluyen de la matriz de entrenamiento X.

Archivo Generado: El dataset resultante se exporta como outputs/dataset_clasificacion.csv.

4.2 Dataset de recomendación

Proceso de Extracción y Transformación

El dataset de recomendación (dataset_recomendacion_interacciones.csv) extrae las coocurrencias de compra entre productos.

Filtro de Registros Válidos: Se filtran únicamente los pedidos con estado **Entregado** (descartando cancelaciones y compras pendientes):

```
const pedidosEntregados = todosPedidos.filter(p => p.estado === 'Entregado');
```

Extracción de Canastas de Compra: Para cada pedido entregado, se extraen los IDs únicos de los productos comprados (productos.producto), eliminando duplicados dentro del mismo pedido.

Construcción del Dataset de Interacción: Se genera una matriz dispersa de presencia binaria: presencia = 1 indicando que el producto_id fue adquirido dentro del pedido_id.

Archivo Generado: Se exporta como outputs/dataset_recomendacion_interacciones.csv con la estructura: [pedido_id, producto_id, nombre_producto, presencia].

4.3 Unidad de análisis de cada dataset

Dataset 1: Clasificación de Riesgo de Cancelación

Definición de Unidad de Análisis: Un pedido de compra individual completo realizado por un cliente en la plataforma e-commerce.

Muestra de 5 renglones (Lenguaje de Negocio):

pedido_id	edad	total	costo_envio	metodo_pago	cancelados_previos	hora_compra	es_fin_de_semana	estado_envio	clase_y	Interpretación de Negocio
PED001	50	\$1,920	\$115	Efectivo	0.0%	8 hrs	0 (No)	Edomex	1	Cliente de 50 años en Edomex pagando en efectivo un pedido

										alto. Se canceló.
PED002	22	\$700	\$125	Transfere ncia	0.0%	10 hrs	0 (No)	Veracruz	1	Cliente joven de Veracruz con costo de flete elevado (\$125). Se canceló.
PED003	29	\$900	\$95	Transfere ncia	0.0%	13 hrs	0 (No)	Puebla	0	Compra en horario laboral con flete moderado . Fue entregado con éxito.
PED004	36	\$395	\$105	Transfere ncia	0.0%	16 hrs	0 (No)	Querétar o	0	Compra pequeña de bajo costo. Fue entregada con éxito.
PED005	31	\$480	\$105	PayPal	0.0%	19 hrs	0 (No)	Querétar o	0	Pago digital seguro con PayPal.

Dataset 2: Recomendación de Productos (Ítem-Ítem)

Definición de Unidad de Análisis: Una interacción de presencia de un producto específico dentro de una compra entregada.

Muestra de 5 renglones (Lenguaje de Negocio):

pedido_id	producto_id	nombre_producto	presencia	Interpretación de Negocio
PED003	PROD_012	Ampolletas Hidraforce - Gegenerex	1	El producto Ampolletas Hidraforce formó parte de la cesta del PED003.
PED003	PROD_045	Alfapar 6.1	1	El tinte Alfapar 6.1 se compró junto con las Ampolletas en el PED003.
PED004	PROD_089	Almohadillas de algodón	1	Almohadillas adquiridas en el pedido entregado PED004.
PED004	PROD_102	4x4 Aftershave King Blue 400ml	1	Aftershave adquirido en el mismo pedido PED004.
PED005	PROD_050	Alfapar 6.23	1	Tinte Alfapar 6.23 presente en la compra exitosa PED005.

4.4 Trazabilidad de columnas


Tabla de Trazabilidad - Dataset 1 (Clasificación)

Columna Final	Significado	Colección de Origen	Campo(s) de Origen	Operación / Transformación	Tipo de Dato	Función en Modelo
pedido_id	ID único de la orden	pedidos	_id	Extracción directa String	String	Rastreo
usuario_id	ID del cliente	pedidos	usuario	FK ObjectId a String	String	Rastreo / Categoría
edad	Edad en años al comprar	usuarios	fechaNacimiento	Año(pedido) - Año(nacimiento)	Entero	Predictora (X)
total	Subtotal en MXN	pedidos	total	Extracción directa float	Flotante	Predictora (X)
costo_envio	Tarifa de envío	pedidos	costoEnvio	Extracción directa float	Flotante	Predictora (X)
metodo_pago	Método de pago	pedidos	metodoPago	One-Hot Encoding (PayPal/Transf/Efectivo)	Categoría	Predictora (X)
num_productos	SKUs en el carrito	pedidos	productos	productos.length	Entero	Predictora (X)

total_unidades	Piezas físicas	pedidos	productos.cantidad	Suma de cantidades	Entero	Predictora (X)
porcentaje_cancelados_previos	% cancelados previo	pedidos	estado	(Cancelaciones previas / Compras previas) * 100	Flotante	Predictora (X)
hora_compra	Hora del día (0-23h)	pedidos	createdAt	createdAt.getHours()	Entero	Predictora (X)
es_fin_de_semana	¿Compra en Sáb/Dom?	pedidos	createdAt	1 si Sáb/Dom sino 0	Binario	Predictora (X)
dias_desde_ultimo_pedido	Días última compra	pedidos	createdAt	(fecha_actual - fecha_previa) / 86,400,000	Flotante	Predictora (X)
antigüedad_cuenta_dias	Antigüedad usuario	usuarios	createdAt	(fecha_pedido - usuario.createdAt) / 86,400,000	Flotante	Predictora (X)
estado_envio	Estado de entrega	pedidos	direccionEnvio.estado	One-Hot Encoding de ubicación	Categoría	Predictora (X)
precio_promedio_unidad	Precio medio pieza	pedidos	total, unidades	total / total_unidades	Flotante	Predictora (X)
unidades_por_producto	Piezas por SKU	pedidos	unidades, num_prods	total_unidades / num_productos	Flotante	Predictora (X)
prop_costo_envio	Proporción flete	pedidos	costoEnvio, total	costo_envio / total	Flotante	Predictora (X)

envio_gratis	Indicador envío \$0	pedidos	costoEnvio	1.0 si costo_envio == 0 sino 0.0	Binario	Predictor a (X)
total_real	Cobro final	pedidos	total, costoEnvio	total + costo_envio	Flotante	Predictor a (X)
clase_y	Riesgo Cancelaci ón	pedidos	estado	1 si Cancelado sino 0	Binario	Objetivo (y)

Diagrama de Flujo de Datos (Arquitectura de Trazabilidad)



4.5 Verificación del proceso

Para demostrar la integridad del pipeline de datos, se realizaron los siguientes controles de validación:

1. Conteos de Registros en Fuentes Originales:

- Total de pedidos en MongoDB: 8,000 registros.
- Total de usuarios no admin en MongoDB: 450 usuarios.
- Total de productos activos en MongoDB: 300 productos.

2. Conteos y Dimensiones de Datasets Finales:

- dataset_clasificacion.csv: 3,000 filas y 18 columnas.
- dataset_recomendacion_interacciones.csv: 6,382 registros de interacción.

3. Verificación de Valores Nulos:

- Porcentaje de valores nulos o faltantes en el dataset final: 0.00%.
- Todos los registros incompletos fueron imputados mediante reglas de negocio neutras en el script de extracción.

4. Distribución de la Variable Objetivo (clase_y):

- Clase 0 (Entregado): 1,980 pedidos (66.0%).
- Clase 1 (Cancelado): 1,020 pedidos (34.0%).
- Balanceo abordado en el modelo mediante class_weight="balanced".

5. Validación de Inconsistencias:

- Se confirmó que no existan edades negativas ($\text{edad} \geq 18$).
- Se verificó que $\text{total_unidades} \geq 1$ y $\text{total} > 0$.
- Se validó que la fecha del pedido sea igual o posterior a la fecha de registro de la cuenta del cliente ($\text{antiguedad_cuenta_dias} \geq 0$).

5. Desarrollo CRISP-DM: Solución 1, Clasificación

5.1 Comprensión del negocio

Contexto del Negocio: Distribuidora Panamericana es un e-commerce de productos de belleza y herramientas de barbería profesional.

Problema a Atender: La cancelación de pedidos ya confirmados inmoviliza stock en almacén, genera costos logísticos de empaque fallido y pérdida de ventas.

Objetivo Analítico: Entrenar un algoritmo de clasificación supervisada (Random Forest) que prediga la probabilidad de cancelación ($y=1$) al momento en que el cliente registra la orden.

Usuario Destino: Administradores del panel web y equipo de logística.

Decisión a Apoyar: Confirmación telefónica prioritaria o solicitud preventiva de comprobante de pago en depósitos en efectivo antes de apartar stock.

Beneficio Esperado: Reducción del 30% en cancelaciones no gestionadas y optimización del inventario.

Riesgo de Error: Un falso positivo tiene bajo costo (una llamada de verificación); un falso negativo tiene alto costo (pérdida de flete y apartado de stock).

Criterio de Utilidad: Accuracy > 75%, PR-AUC > 80% y F1-Score > 75% evaluados con Validación Cruzada K-Fold = 5.

5.2 Comprensión de los datos

Colecciones: pedidos, usuarios, productos.

Volumen y Periodo: 3,000 pedidos transaccionales analizados de un periodo de 2024 a 2026 sobre 450 usuarios únicos.

Atributos: 19 variables (edad, total, costo_envio, metodo_pago, hora_compra, es_fin_de_semana, dias_desde_ultimo_pedido, antiguedad_cuenta_dias, etc.).

Estadísticas: Edad promedio 35.2 años, total promedio \$1,120.50 MXN.

Calidad: 0% de duplicados y 0% de valores nulos.

5.3 Preparación de los datos

Feature Engineering: Creación de 5 variables derivadas (precio_promedio_unidad, unidades_por_producto, prop_costo_envio, envio_gratis, total_real).

Encoding: One-Hot Vectorization de categóricas (metodo_pago, estado_envio) mediante DictVectorizer.

Prevención de Fuga de Datos: Ordenamiento cronológico estricto (createdAt 1) para que el historial del cliente no consulte compras futuras.

5.4 Modelado

Algoritmo: RandomForestClassifier (300

árboles, max_depth=12, min_samples_split=10, min_samples_leaf=4, class_weight="balanced").

5.5 Evaluación

Resultados K-Fold = 5:

Accuracy: 76.5% $\pm$ 0.5%

Balanced Accuracy: 77.4% $\pm$ 0.4%

Precisión: 88.1% $\pm$ 0.4%

Recall: 74.7% $\pm$ 1.0%

F1-Score: 80.8% $\pm$ 0.5%

PR-AUC: 91.5% $\pm$ 0.4%

Matriz de Confusión: 822 Verdaderos Positivos, 413 Verdaderos Negativos, 126 Falsos Positivos, 239 Falsos Negativos.

5.6 Despliegue e integración

Artefacto: Pipeline serializado en disco como modelo_random_forest_cancelacion.joblib.

Backend Node.js: Carga mediante randomForestCancelacionService.js / analiticaService.js en el endpoint GET /api/pedidos/analitica/riesgos consumido por Angular en tiempo real.

6. Desarrollo CRISP-DM: Solución 2, Recomendación

6.1 Comprensión del negocio

Contexto del Negocio: Venta cruzada (*Cross-Selling*) en el carrito de compras del e-commerce.

Problema a Atender: Los clientes compran solo 1 o 2 artículos sin explorar herramientas o insumos complementarios.

Objetivo Analítico: Sugerir los 6 productos con mayor afinidad mediante **Filtrado**

Colaborativo Ítem-Ítem (Similitud Coseno por Coocurrencia).

Usuario Destino: Comprador final en la tienda web (vista de carrito y detalle de producto).

Decisión a Apoyar: Mostrar la sección "Frecuentemente comprados juntos".

Beneficio Esperado: Aumentar las piezas por orden de 1.8 a más de 3.0.

Criterio de Utilidad: Generar recomendaciones coherentes (ej. Peróxido con Tinte; Cuchilla de repuesto con Máquina barbera) respondiendo en < 100 ms.

6.2 Comprensión de los datos

Datos: 2,696 canastas de compras en estado Entregado, 300 productos activos y 6,382 pares con coocurrencia.

6.3 Preparación de los datos

Extracción de pedidos entregados y construcción de la matriz dispersa de coocurrencia binaria.

6.4 Modelado

Fórmula de Similitud Coseno:

$$Similitud(A, B) = \frac{A \cap B}{\sqrt{A \times B}}$$

6.5 Evaluación

Verificación cualitativa de coherencia comercial y visualización del Mapa de Calor (Heatmap).

6.6 Despliegue e integración

Artefacto e Integración: Modelo en memoria en analiticaService.js consultado dinámicamente vía GET /api/productos/recomendaciones?productos=ID1,ID2 respondiendo en menos de 15 ms.

7. Requisitos específicos según el tipo de solución

7.1 Solución 1: Clasificación del Riesgo de Cancelación

1. Definición de Clases

- **Clase 0 (Entregado):** El pedido fue procesado, enviado y entregado exitosamente al cliente.
- **Clase 1 (Cancelado):** El pedido fue anulado o cancelado antes del envío (evento de riesgo).

2. Variable Objetivo (y)

- `clase_y` binaria (1 si es Cancelado, 0 si es Entregado).

3. Análisis del Balance de Clases

- **Distribución:** 1,980 Entregados (66.0%) vs 1,020 Cancelados (34.0%).
- **Estrategia:** Se configuró `class_weight="balanced"` en `RandomForestClassifier` para equilibrar la penalización de errores en la clase minoritaria.

4. Prevención de Fugas de Información (*Data Leakage*)

- Se eliminaron variables posteriores como `fechaCancelacion` y `pago.estado`.
- El atributo `porcentaje_cancelados_previos` se calcula exclusivamente con pedidos anteriores en orden cronológico (`createdAt < fecha_actual`).

5. Estrategia de Validación

- **Validación Cruzada Estratificada:** `StratifiedKFold(n_splits=5, shuffle=True, random_state=42)`.

- **Hold-Out:** 80% entrenamiento / 20% prueba.

6. Matriz de Confusión y Métricas de Evaluación

- **Matriz de Confusión:** 822 Verdaderos Positivos, 413 Verdaderos Negativos, 126 Falsos Positivos, 239 Falsos Negativos.
- **Métricas:** Accuracy 76.5%, Balanced Accuracy 77.4%, Precisión 88.1%, Recall 74.7%, F1-Score 80.8%, PR-AUC 91.5%.

7. Análisis de Costo del Error para el Negocio

- **Falso Positivo** (Llamada preventiva a un cliente legítimo): Costo muy bajo (< \$5 MXN).
- **Falso Negativo** (No detectar una cancelación real): Costo alto (\$150 - \$300 MXN en flete, empaque e inventario inmovilizado).
- **Conclusión:** Se optimizó la Precisión (88.1%) y el PR-AUC (0.915) para minimizar los falsos negativos costosos.

8. Integración para Clasificar Nuevos Casos

- Carga del archivo .joblib en el Backend Node.js para clasificar pedidos dinámicamente en vivo.

7.2 Solución 2: Sistema de Recomendación (Filtrado Colaborativo Ítem-Ítem)

1. Información Conocida

- Artículos agregados activamente al carrito y catálogo de 300 productos.

2. Representación de Preferencias

- Interacciones implícitas de compra comprobada (presencia = 1 en pedidos entregados).

3. Cálculo de Similitud y Ranking

- **Similitud Coseno por Coocurrencia:**

$$Similitud(A, B) = \frac{A \cap B}{\sqrt{A \times B}}$$

4. Resolución de Usuarios/Elementos Nuevos (*Cold-Start*)

- Mecanismo de respaldo (*Fallback*) jerárquico por contenido: primero por Familia, luego por Marca, y finalmente por Popularidad Global.

5. Número de Recomendaciones Devueltas

- Devuelve exactamente 6 productos para adaptarse al diseño de carrusel visual sin saturar la pantalla.

6. Línea Base de Comparación

- Comparado contra recomendación simple por Popularidad Global, superando a la línea base al dar sugerencias contextualizadas al carrito.

7. Evaluación de la Calidad

- Evaluado mediante cobertura del catálogo (300 SKUs), inspección de mapa de calor (*Heatmap*) y coherencia cualitativa de negocio (Tinte -> Peróxido/Brocha; Trimmer -> Enfriador).

8. Integración en el sistema web

8.1 Arquitectura general

Frontend: Angular 17+ (Single Page Application, TypeScript, HTML5, Vanilla CSS, Angular Material).

Backend: Node.js con Express.js (API RESTful).

Base de Datos: MongoDB gestionado mediante Mongoose ODM.

Entrenamiento IA/ML: Python 3.10+ con scikit-learn, pandas y joblib.

8.2 Integración del modelo de clasificación

Módulo Web: Panel de Administración de Ventas (/admin/pedidos).

Servicio Backend: services/randomForestCancelacionService.js / analiticaService.js.

Punto de Entrada en Código: Controller pedidoController.js en la función getAnaliticaRiesgo.

Preparación Automática: El backend calcula automáticamente la edad, cancelados previos, características temporales/geográficas y proporciones numéricas sin pedir datos codificados al usuario.

Formato de Respuesta: JSON estructurado retornando el nivel de riesgo (Alto, Medio, Bajo), probabilidad y acción sugerida.

8.3 Integración del recomendador

Módulo Web: Carrito de Compras (/carrito) y Detalle de Producto (/producto/:id).

Servicio Backend: services/analiticaService.js en la función recomendarProductos.

Preparación Automática: Extrae los producto_id presentes en el carrito sin solicitar entradas manuales.

Formato de Respuesta: JSON con el listado de 6 productos recomendados ordenados por Similitud Coseno con metadatos de producto completos.

Manejo de Carritos Vacíos (*Fallback*): Estrategia jerárquica que retorna productos populares de la misma Familia, Marca o Catálogo general.

8.4 Endpoints y servicios utilizados

Método HTTP	Endpoint URL	Autenticación	Módulo Frontend	Descripción del Servicio
GET	/api/pedidos/analitica/riesgos	Requiere Token JWT (admin)	Admin Dashboard (/admin/pedidos)	Calcula el riesgo de cancelación sobre pedidos activos.
GET	/api/productos/recomendaciones	Pública (Sin Token)	Carrito / Producto (/carrito)	Retorna 6 productos recomendados por Similitud Coseno.
GET	/api/pedidos	Requiere Token JWT	Lista de Pedidos	Retorna compras ordenadas con índices en MongoDB.

8.5 Actualización de modelos o cálculos

Procedimiento:

Ejecución del script node generar_dataset_optimo.js.

Re-entrenamiento en Jupyter Notebook (01_clasificacion_riesgo_cancelacion.ipynb)

exportando modelo_random_forest_cancelacion.joblib.

Reemplazo del archivo .joblib en el Backend de Node.js.

Ventaja: Despliegue sin interrupciones del servicio (*Zero Downtime*) y sin requerir cambios en el código cliente de Angular.

9. Evidencias de funcionamiento

9.1 Evidencias de clasificación

Caso de Prueba 1: Pedido Transaccional en Proceso (Riesgo Medio)

- **Datos de Entrada:** Pedido 9d0c4d registrado por el cliente deivid (odlc31230@gmail.com) el 01/08/2026 por un total de \$895.00 MXN (4 productos: Alain silver tratamiento, Aashta clip, Alaska brocha y Aashta kit). Método de Pago: PayPal (Estado pasarela: *Pago pendiente / sin confirmar cargo*).
- **Ejecución desde el Sistema Web:** El cliente confirma el checkout y la orden ingresa con estado Pendiente. El administrador abre la pantalla de Gestión de Pedidos (/admin/pedidos) y la API REST consulta el artefacto .joblib en tiempo real.
- **Resultado Obtenido:** Insignia visual 51% - Medio (Riesgo Medio en color amarillo).
- **Interpretación del Resultado:** El modelo identificó que el pago en PayPal no fue capturado de inmediato ("*Pago pendiente. No se realizó ningún cargo. El pedido quedó reservado durante una hora*").
- **Acción Sugerida:** El administrador retiene el despacho y espera la confirmación de la pasarela o envía un recordatorio automático al cliente.
- **Correspondencia con la Libreta:** Coincide al 100% con las reglas evaluadas en 01_clasificacion_riesgo_cancelacion.ipynb.

Dirección de envío

asdad
asdads, asdadsa, CP asdasda
Tel. asdada
CAMBIAR

Método de pago

PayPal
CAMBIAR

Resumen del pedido

1 × Alain silv	\$140.00
1 × Aashta c	\$45.00
1 × Alaska b	\$60.00
1 × aashta k	\$650.00
Envío	\$0.00
Total	\$895.00



Pago pendiente

No se realizó ningún cargo. El pedido quedó reservado durante una hora y puedes reintentarlo en Mis compras.

OK

Confirmar y p


PayPal mostrará las f

PayPal

 Debit or Credit Card

Powered by PayPal

VOLVER



9.2 Evidencias de recomendación

Caso de Prueba 1: Recomendaciones en Detalle de Producto (*Cross-Selling*)

- **Vista Web:** Detalle de Producto (/producto/4x4-combo-barber-5pz).
- **Producto Semilla:** "4X4 oferta combo barber de 5 pz." (\$950.00 MXN).
- **Ejecución:** La API consulta la matriz de similitud Coseno calculada sobre 2,696 canastas de compras entregadas.

- **Resultado Obtenido (6 Recomendaciones):**

1. Alfapar 6NI (\$160.00)
2. 4X4 Gel para afeitar menta 1kg (\$160.00)
3. aashta tijera ps154 (\$250.00)
4. Adhesivo Para Pestañas Duo Transparente (\$80.00)
5. 4X4 Maquina platino 10000 RPM (\$1,500.00)
6. Aashta tijeras negro no. 7 (\$250.00)

- **Interpretación:** Identificó una fuerte coocurrencia de compra entre combos de barbería e insumos de afeitado, herramientas de corte y tintes de retoque.



4X4 / GENERAL

4X4 oferta combo barber de 5 pz.

Producto profesional disponible en nuestro catálogo exclusivo.

\$950.00

33 unidades disponibles

 AÑADIR AL CARRITO

SKU	XXX-GEN-001-N
MAYOREO	\$850.00
CAJA	\$0.00

RECOMENDACIÓN PERSONALIZADA

Productos recomendados

Productos que suelen comprarse junto con tu selección

 COMPRADO JUNTO CON ESTE PRODUCTO Alfaparc 6NI \$160.00  AGREGAR	 COMPRADO JUNTO CON ESTE PRODUCTO 4X4 Gel para afeitar menta 1kg \$160.00  AGREGAR	 COMPRADO JUNTO CON ESTE PRODUCTO aashta tijera perla \$250.00  AGREGAR
 COMPRADO JUNTO CON ESTE PRODUCTO Adhesivo Para Pestañas Duo Transparente \$80.00  AGREGAR	 COMPRADO JUNTO CON ESTE PRODUCTO 4x4 Máquina platino 10000 RPM \$1,500.00  AGREGAR	 COMPRADO JUNTO CON ESTE PRODUCTO Aashta tijeras negro no. 7 \$250.00  AGREGAR

Caso de Prueba 2: Recomendaciones en Carrito de Compras (*Completa tu compra*)

- **Vista Web:** Carrito de Compras (/carrito).
- **Productos Semillas:** Alain silver tratamiento, Aashta clip, Alaska brocha barbero y Aashta kit 2 pz (Subtotal \$895.00 MXN).

- **Resultado Obtenido (6 Recomendaciones en Carrito):**

1. **Alfapar 5.66I** (\$160.00)
2. **4X4 Pomada Azul 200g** (\$140.00)
3. **Alfapar 7000** (\$160.00)
4. **Alfapar 6.23** (\$160.00)
5. **adhesivo latex para rulos o pads liftin j denis** (\$65.00)
6. **Alicate Alaska Manicure** (\$110.00)

- **Correspondencia con la Libreta:** Al igual que en 02_recomendacion_colaborativa_item_item.ipynb, el backend combina los puntajes de las 4 semillas del carrito ofreciendo sugerencias variadas de fijación, manicura y colorimetría para elevar el ticket promedio.

Tu Carrito de Compras



Alain silver tratamiento
\$140.00

-

1

+

\$140.00



Aashta clip metalico o sojetador
\$45.00

-

1

+

\$45.00



Alaska brocha barbero
\$60.00

-

1

+

\$60.00



aashta kit 2 pz.
\$650.00

-

1

+

\$650.00

VACIAR CARRITO

Resumen del Pedido

Subtotal

\$895.00

Envio

CALCULADO AL PAGAR

Total

\$895.00

PROCEDER AL PAGO

RECOMENDACION PERSONALIZADA

Completa tu compra

Productos que suelen comprarse junto con tu seleccion.



ALFAPAR
5.66l
CORTADO CLARO
ROJO PIRREDO

COMPRADO JUNTO CON ESTE PRODUCTO
Alfapar 5.66l
\$160.00

AGREGAR



4x4

COMPRADO JUNTO CON ESTE PRODUCTO
4x4 Pomada Azul 200g
\$140.00

AGREGAR



7000

COMPRADO JUNTO CON ESTE PRODUCTO
Alfapar 7000
\$160.00

AGREGAR



6.23

COMPRADO JUNTO CON ESTE PRODUCTO
Alfapar 6.23
\$160.00

AGREGAR



COMPRADO JUNTO CON ESTE PRODUCTO
adhesivo latex para rulos o pads
liftin j dents
\$65.00

AGREGAR



COMPRADO JUNTO CON ESTE PRODUCTO
Alicate Alaska Manicure
\$110.00

AGREGAR

10. Resultados, limitaciones y mejoras

10.1 Resultados obtenidos

Resumen de Métricas Alcanzadas por Solución

1. Solución 1: Clasificación de Riesgo de Cancelación (Random Forest)

- Accuracy Promedio: $76.5\% \pm 0.5\%$
- Balanced Accuracy: $77.4\% \pm 0.4\%$
- Precisión Promedio: $88.1\% \pm 0.4\%$
- Recall Promedio: $74.7\% \pm 1.0\%$
- F1-Score Promedio: $80.8\% \pm 0.5\%$
- PR-AUC Promedio: $91.5\% \pm 0.4\%$
- Estabilidad: Validado mediante Validación Cruzada Estratificada (K-Fold = 5) sobre 3,000 observaciones y 19 características base y derivadas.

2. Solución 2: Recomendación de Productos (Filtrado Colaborativo Ítem-Ítem)

- Canastas de Compra Entregadas: 2,696 pedidos analizados.
- Catálogo Cubierto: 300 productos activos.
- Pares de Coocurrencia: 6,382 relaciones de co-compra.
- Desempeño: Sugiere los 6 productos con mayor afinidad Coseno en tiempo real respondiendo en menos de 15 milisegundos.

Impacto en la Operación de Distribuidora Panamericana

- **Prevención de Pérdidas:** Permite al equipo de operaciones anticipar hasta un 74.7% de las cancelaciones antes de empaquetar o despachar inventario.
- **Venta Cruzada (*Cross-Selling*):** Facilita la adición de artículos complementarios con un solo clic, aumentando el promedio de unidades por transacción.

10.2 Limitaciones de los datos

A pesar de los excelentes resultados alcanzados, se identifican las siguientes limitaciones en el dataset actual:

1. **Naturaleza Sintética del Historial:** Dado que Distribuidora Panamericana no contaba con un archivo digital histórico superior a 2,000 pedidos, el 100% de las transacciones se construyó de forma sintética (con semilla fija reproduciendo reglas de negocio reales).
2. **Ausencia de Variables de Pasarela Bancaria:** El dataset no incluye registros de reintentos fallidos de tarjeta de crédito, verificaciones 3D Secure ni códigos de rechazo bancario en tiempo real.
3. **Falta de Módulo de Tickets de Soporte:** La base de datos actual no registra quejas previas o reclamaciones históricas por cliente.

10.3 Riesgos de errores del modelo

Se analizan los riesgos operacionales derivados de los dos posibles tipos de error del modelo predictivo:

Riesgo por Falso Positivo (Predicción: Cancelado | Realidad: Entregado):

- *Efecto:* Se genera una alerta de riesgo medio/alto en una orden legítima.
- *Mitigación:* El sistema no cancela la orden automáticamente; solo sugiere una verificación telefónica o confirmación de datos. El impacto en el cliente es mínimo.

Riesgo por Falso Negativo (Predicción: Entregado | Realidad: Cancelado):

- *Efecto:* Una orden que terminará cancelándose no se detecta a tiempo.
- *Mitigación:* Se optimizó el modelo para alcanzar una **Precisión del 88.1%** y **PR-AUC del 91.5%**, minimizando los falsos negativos a un porcentaje residual aceptable para la empresa.

10.4 Mejoras futuras

Para evolucionar el sistema analítico en una versión 2.0 en producción, se proponen las siguientes mejoras técnicas:

1. **Captura de Comportamiento Web en Tiempo Real (*Clickstream*):** Incorporar métricas de navegación previa del usuario (tiempo de permanencia en la ficha del producto, número de visitas a la categoría y productos guardados en lista de deseos).
2. **Integración con Webhooks de Pasarelas de Pago:** Conectar eventos en vivo de PayPal y Stripe para incluir respuestas de autorización bancaria directamente como variables del modelo.
3. **Sistemas de Recomendación Híbridos (*Vector Embeddings*):** Evolucionar la recomendación por Coocurrencia Coseno hacia un modelo Híbrido que combine Filtrado Colaborativo con embeddings de texto/categorías mediante técnicas de Factorización de Matrices (SVD) o embeddings de productos.
4. **Re-entrenamiento Automático Programado (*Cron Jobs*):** Implementar tareas automáticas en Node.js que re-entrenen y actualicen la matriz de similitud y el artefacto .joblib semanalmente con las ventas reales acumuladas.

11. Conclusiones

El desarrollo del proyecto integrador para Distribuidora Panamericana ha permitido transformar la plataforma de comercio electrónico tradicional en un sistema inteligente impulsado por Analítica de Datos y Machine Learning, logrando la integración exitosa de dos soluciones analíticas avanzadas:

Clasificación del Riesgo de Cancelación de Pedidos (Random Forest): Se alcanzó y superó el objetivo técnico fijado al obtener un Accuracy del 76.5%, una Precisión del 88.1% y un PR-AUC del 91.5% evaluados mediante Validación Cruzada Estratificada (K-Fold = 5). Esta solución provee al equipo administrativo una herramienta predictiva en tiempo real que previene pérdidas financieras e ineficiencias logísticas asociadas al empaque y apartado no gestionado de inventario.

Sistema de Recomendación de Productos (Filtrado Colaborativo Ítem-Ítem): A través del cálculo de Similitud Coseno por Coocurrencia sobre 2,696 canastas de compra entregadas, el sistema sugiere 6 productos afines en la vista de detalle y en el carrito de compras con un tiempo de respuesta inferior a 15 milisegundos. Esto impulsa la estrategia de venta cruzada (*Cross-Selling*) y eleva el ticket promedio de compra.

Adopción de la Metodología CRISP-DM: La estructuración del proyecto bajo las seis fases de CRISP-DM garantizó la trazabilidad total del dato: desde la extracción reproducible en MongoDB, el procesamiento en libretas Jupyter/Python, la serialización de modelos con joblib, hasta el despliegue final en la arquitectura web desacoplada (Node.js/Express API + Angular 17+).

En conclusión, el proyecto demuestra cómo la aplicación rigurosa de la ciencia de datos resuelve problemas reales de negocio en el sector de distribución de productos de belleza y barbería, sentando las bases para una operación escalable y rentable.

12. Bibliografía

- Breiman, L. (2001). Random Forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic Minority Over-sampling Technique. *Journal of Artificial Intelligence Research*, 16, 321–357. <https://doi.org/10.1613/jair.953>
- Mongoose ODM. (2024). *Mongoose v8.0.0 Documentation: Elegant MongoDB object modeling for Node.js*. <https://mongoosejs.com/docs/>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research*,